

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Sieci neuronowe

(projekt)

Wykorzystanie sieci VGG19
do klasyfikacji owoców

Drelich Ewelina, Dziurlikowski Krzysztof,
Pawlak Iga, Pierczyk Krzysztof

Warszawa, 10 stycznia 2021

Streszczenie

Sztuczne sieci neuronowe na stałe zadomowiły się w dziedzinie, którą dzisiaj powszechnie określamy mianem sztucznej inteligencji. Algorytmy tworzone przez takie firmy jak Google potrafią już same uczyć się operowania w tak złożonych grach jak szachy czy Starcraft II znacząco przewyższając wynikami ludzi [1]. Coraz częściej pojawiają się również w bardziej egzotycznych obszarach sterując balonami stratosferycznymi [2] czy przewidując struktury przestrzenne długich łańcuchów aminokwasowych [3].

Jednym z klasycznych zastosowań sieci neuronowych jest klasyfikacja obrazów. Wśród najpowszechniej używanych w tym celu architektur znajduje się od dłuższego czasu zaproponowana w 2014 roku *VGG* [4]. Niniejsza praca skupia się na jednym z wariantów tego modelu - *VGG19* - analizując jego możliwości w kontekście klasyfikacji obrazów owoców ze zbioru *Fruits-360* [5]. Pierwsze trzy rozdziały stanowią opis postawionego problemu, wykorzystanej architektury oraz zbioru danych. Rozdział 4 opisuje przypadki uczenia klasyfikatorów typu perceptronowego oraz SVM bazujących na cechach generowanych przez warstwy splotowe sieci *VGG19* uprzednio wytrenowanej na zbiorze *ImageNet*. Następnie przedstawiony został trening części klasyfikującej (typu perceptronowego) wraz z częścią lub wszystkimi warstwami splotowymi. Przedostatni rozdział zgłębia analizę wytrenowanych sieci wykorzystując techniki wizualizacji obszarów uwagi oraz stopnia aktywacji poszczególnych warstw sieci.

- 1 Analiza zadania
- 2 Architektura VGG19
- 3 Zbiór danych
 - 3.1 Potok
 - 3.2 Augmentacja
- 4 Klasyfikatory
 - 4.1 Klasyfikator perceptronowy
 - 4.2 Maszyna Wektorów Wspierających
 - 4.3 Porównanie wyników
- 5 Sieci głębokie
 - 5.1 Uczenie ostatniej warstwy splotowej
 - 5.2 Uczenie dwóch ostatnich warstw splotowych
 - 5.3 Uczenie pełnej sieci
 - 5.4 Uczenie sieci o uproszczonej strukturze
 - 5.5 Porównanie wyników
- 6 Wizualizacja
 - 6.1 Przypadek klasyfikatora perceptronowego
 - 6.2 Maszyna Wektorów Wspierających
 - 6.3 Przypadek ostatniej warstwy splotowej
 - 6.4 Przypadek dwóch ostatnich warstw splotowych
 - 6.5 Przypadek pełnej sieci
 - 6.6 Przypadek sieci o uproszczonej strukturze
 - 6.7 Porównanie wyników
- 7 Podsumowanie

Bibliografia

- [1] J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, T. Lillicrap i D. Silver, „Mastering Atari, Go, chess and shogi by planning with a learned model,” *Nature*, nr. 588, s. 604–609, 2020.
- [2] M. G. Bellemare, S. Candido, P. S. Castro, J. Gong, M. C. Machado, S. Moitra, S. S. Ponda i Z. Wang, „Autonomous navigation of stratospheric balloons using reinforcement learning,” *Nature*, nr. 588, s. 77–82, 2020.
- [3] A. W. Senior, R. Evans, J. Jumper, J. Kirkpatrick, L. Sifre, T. Green, C. Qin, A. Žídek, A. W. R. Nelson, A. Bridgland, H. Penedones, S. Petersen, K. Simonyan, S. Crossan, P. Kohli, D. T. Jones, D. Silver, K. Kavukcuoglu i D. Hassabis, „Improved protein structure prediction using potentials from deep learning,” *Nature*, nr. 577, s. 706–710, 2020.
- [4] K. Simonyan i A. Zisserman, „Very Deep Convolutional Networks for Large-Scale Image Recognition,” 2014.
- [5] H. Muresan i M. Oltean, „Fruit recognition from images using deep learning,” *Informatica*, nr. 10, s. 26–42, 2018. adr.: <http://web.archive.org/web/20080207010024/http://www.808multimedia.com/winnt/kernel.htm>.