

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI  
I TECHNIK INFORMACYJNYCH



# Sieci neuronowe

(projekt)

Wykorzystanie sieci VGG19  
do klasyfikacji owoców

Drelich Ewelina, Dziurlikowski Krzysztof,  
Pawlak Iga, Pierczyk Krzysztof

Warszawa, 8 stycznia 2021

# Spis treści

<b>1. Analiza zadania</b>	<b>4</b>
<b>2. Architektura VGG19</b>	<b>4</b>
<b>3. Zbiór danych</b>	<b>4</b>
3.1. Potok . . . . .	4
3.2. Augmentacja . . . . .	4
<b>4. Klasyfikatory</b>	<b>4</b>
4.1. Klasyfikator perceptronowy . . . . .	4
4.2. Maszyna Wektorów Wspierających . . . . .	4
4.3. Porównanie wyników . . . . .	4
<b>5. Sieci głębokie</b>	<b>4</b>
5.1. Uczenie ostatniej warstwy splotowej . . . . .	4
5.2. Uczenie dwóch ostatnich warstw splotowych . . . . .	4
5.3. Uczenie pełnej sieci . . . . .	4
5.4. Uczenie sieci o uproszczonej strukturze . . . . .	4
5.5. Porównanie wyników . . . . .	4
<b>6. Wizualizacja</b>	<b>4</b>
6.1. Przypadek klasyfikatora perceptronowego . . . . .	4
6.2. Maszyna Wektorów Wspierających . . . . .	4
6.3. Przypadek ostatniej warstwy splotowej . . . . .	4
6.4. Przypadek dwóch ostatnich warstw splotowych . . . . .	4
6.5. Przypadek pełnej sieci . . . . .	4
6.6. Przypadek sieci o uproszczonej strukturze . . . . .	4
6.7. Porównanie wyników . . . . .	4
<b>7. Podsumowanie</b>	<b>4</b>
<b>Bibliografia</b>	<b>5</b>

## Streszczenie

Sztuczne sieci neuronowe na stałe zadomowiły się w dziedzinie, którą dzisiaj powszechnie określamy mianem sztucznej inteligencji. Algorytmy tworzone przez takie firmy jak Google potrafią już same uczyć się operowania w tak złożonych grach jak szachy czy Starcraft II znacząco przewyższając wynikami ludzi [1]. Coraz częściej pojawiają się również w bardziej egzotycznych obszarach sterując balonami stratosferycznymi [2] czy przewidyując struktury przestrzenne długich łańcuchów aminokwasowych [3].

Jednym z klasycznych zastosowań sieci neuronowych jest klasyfikacja obrazów. Wśród najpowszechniej używanych w tym celu architektur znajduje się od dłuższego czasu zaproponowana w 2014 roku *VGG* [4]. Niniejsza praca skupia się na jednym z wariantów tego modelu - *VGG19* - analiząc jego możliwości w kontekście klasyfikacji obrazów owoców ze zbioru *Fruits-360* [5]. Pierwsze trzy rozdziały stanowią opis postawionego problemu, wykorzystanej architektury oraz zbioru danych. Rozdział 4 opisuje przypadki uczenia klasyfikatorów typu perceptronowego oraz SVM bazujących na cechach generowanych przez warstwy splotowe sieci *VGG19* uprzednio wytrenowanej na zbiorze *ImageNet*. Następnie przedstawiony został trening części klasyfikującej (typu perceptronowego) wraz z częścią lub wszystkimi warstwami splotowymi. Przedostatni rozdział zgłębia analizę wytrenowanych sieci wykorzystując techniki wizualizacji obszarów uwagi oraz stopnia aktywacji poszczególnych warstw sieci.



## 1. Analiza zadania

## 2. Architektura VGG19

## 3. Zbiór danych

### 3.1. Potok

### 3.2. Augmentacja

## 4. Klasyfikatory

### 4.1. Klasyfikator perceptronowy

### 4.2. Maszyna Wektorów Wspierających

### 4.3. Porównanie wyników

## 5. Sieci głębokie

### 5.1. Uczenie ostatniej warstwy splotowej

### 5.2. Uczenie dwóch ostatnich warstw splotowych

### 5.3. Uczenie pełnej sieci

### 5.4. Uczenie sieci o uproszczonej strukturze

### 5.5. Porównanie wyników

## 6. Wizualizacja

### 6.1. Przypadek klasyfikatora perceptronowego

### 6.2. Maszyna Wektorów Wspierających

### 6.3. Przypadek ostatniej warstwy splotowej

### 6.4. Przypadek dwóch ostatnich warstw splotowych

### 6.5. Przypadek pełnej sieci

### 6.6. Przypadek sieci o uproszczonej strukturze

### 6.7. Porównanie wyników

## 7. Podsumowanie

## Bibliografia

- [1] J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, T. Lillicrap i D. Silver, „Mastering Atari, Go, chess and shogi by planning with a learned model,” *Nature*, nr. 588, s. 604–609, 2020.
- [2] M. G. Bellemare, S. Candido, P. S. Castro, J. Gong, M. C. Machado, S. Moitra, S. S. Ponda i Z. Wang, „Autonomous navigation of stratospheric balloons using reinforcement learning,” *Nature*, nr. 588, s. 77–82, 2020.
- [3] A. W. Senior, R. Evans, J. Jumper, J. Kirkpatrick, L. Sifre, T. Green, C. Qin, A. Židek, A. W. R. Nelson, A. Bridgland, H. Penedones, S. Petersen, K. Simonyan, S. Crossan, P. Kohli, D. T. Jones, D. Silver, K. Kavukcuoglu i D. Hassabis, „Improved protein structure prediction using potentials from deep learning,” *Nature*, nr. 577, s. 706–710, 2020.
- [4] K. Simonyan i A. Zisserman, „Very Deep Convolutional Networks for Large-Scale Image Recognition,” 2014.
- [5] H. Muresan i M. Oltean, „Fruit recognition from images using deep learning,” *Informatica*, nr. 10, s. 26–42, 2018. adr.: <http://web.archive.org/web/20080207010024/http://www.808multimedia.com/winnt/kernel.htm>.